МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ
НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ
«КИЇВСЬКИЙ ПОЛІТЕХНІЧНИЙ ІНСТИТУТ ІМЕНІ ІГОРЯ СІКОРСЬКОГО»
ІНСТИТУТ ПРИКЛАДНОГО СИСТЕМНОГО АНАЛІЗУ
КАФЕДРА ШТУЧНОГО ІНТЕЛЕКТУ

**ЗВІТ**

про виконання лабораторної роботи № 2

з дисципліни "Інтелектуальна обробка голосової інформації"

**Варіант 1**

**Виконали:**

Студенти 5 курсу групи КІ-51 мп

Архіпов Яків,

Польнікова Поліна

Ткаченко Марія

**Перевірив:**

Сидорський В. С.

Київ – 2025

## ЗАВДАННЯ (ВАРІАНТ 1)

Вирішити задачу розпізнавання співу птахів на прикладі BirdCLEF+ 2026.

1. Проаналізувати існуючі рішення, а також рішення з попередніх змагань (наприклад BirdCLEF+ 2025)
2. Провести Exploratory Data Analysis
3. Побудувати Валідацію
4. Проаналізувати запропоновану метрику та запропонувати інші метрики
5. Розробити декілька моделей (як мінімум 3 підхода)
6. Провалідувати а також завантажити рішення на Kaggle – отримати результат на Leaderboard
7. Проаналізувати корреляцію валідаційних метрик і метрики на Leaderboard
8. Порівняти поточне змагання з попередніми BirdCLEF

# ХІД РОБОТИ

## 1. ОГЛЯД ДАНИХ, ОСНОВНІ ОСОБЛИВОСТІ Й ПРОБЛЕМИ

Під час розвідувального аналізу даних (EDA) тренувального набору BirdCLEF було досліджено метадані та аудіофайли для виявлення ключових патернів, аномалій та потенційних проблем, які можуть вплинути на навчання моделі. Було виділено кілька критичних особливостей датасету.

### 1.1. Дисбаланс класів та представленість видів

Змагання передбачає розпізнавання 234 видів птахів, однак аналіз тренувальних даних показав, що 28 видів повністю відсутні як в основних (primary_label), так і у другорядних мітках (secondary_labels). Таким чином, навчальна вибірка містить записи лише 206 унікальних класів.

Крім того, спостерігається сильний дисбаланс класів. Деякі поширені види мають понад 500 аудіозаписів, тоді як рідкісні види представлені лише 1–5 файлами.

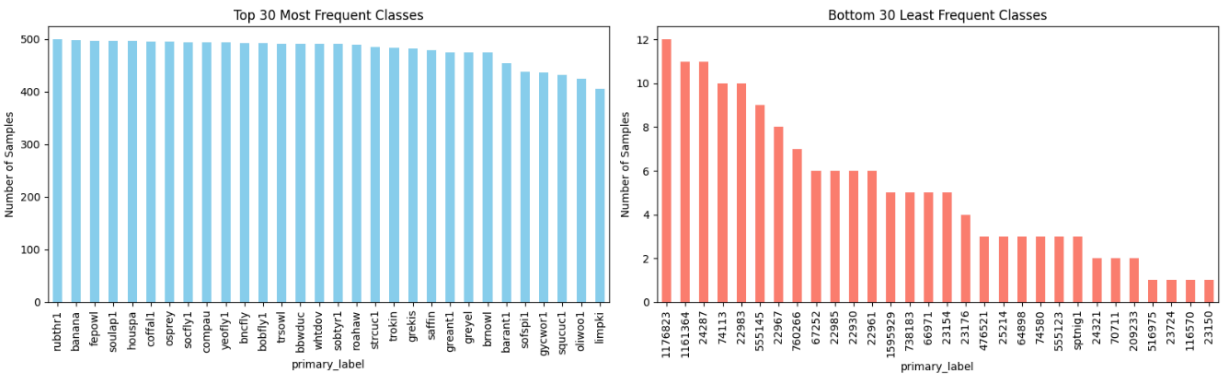


Рисунок 1 – Гістограма розподілу кількості записів за класами

Такий дисбаланс може призвести до перенавчання на мажоритарних класах, тому дуже важливо буде це врахувати.

### 1.2. Тривалість записів та частота дискретизації

Аудіофайли мають суттєво різну тривалість. Більшість записів тривають до 1 хвилини, однак зустрічаються файли тривалістю понад годину. Проблема – правилами змагання передбачено оцінювання 5-секундних вікон.

```
--- Audio Duration Statistics (seconds) ---
Minimum duration: 0.01
Maximum duration: 6881.10
Mean duration: 34.88
Median duration: 21.00
```

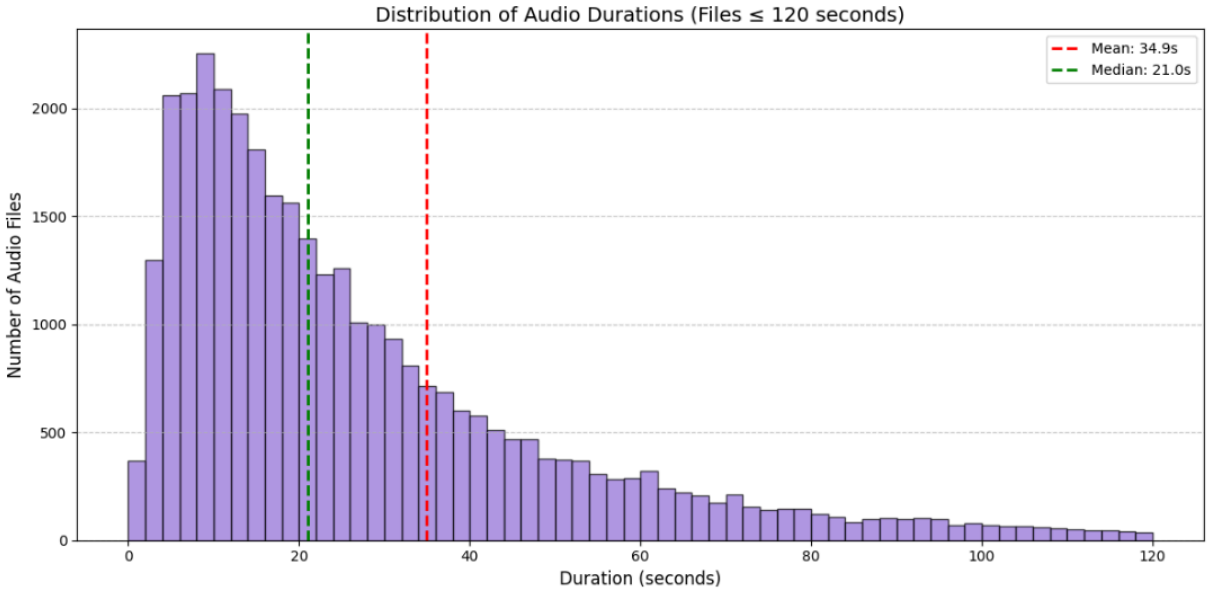


```
Percentage of files 120 seconds or shorter: 96.17%
```

Рисунок 2 – Розподіл тривалості аудіофайлів

Перевірка частоти дискретизації (Sample Rate) показала, що всі файли записано з частотою 32 000 Гц, як і було заявлено.

У наданих метаданих повністю відсутня часова розмітка. Датасет містить мітки лише на рівні всього файлу, тобто відомо, що птах присутній у записі, але

немає точних часових міток початку та кінця його вокалізації, що також породжує проблеми.

### 1.3 Оцінки якості аудіо та наявність фонових видів

Аналіз колонки рейтингів показав, що понад 36% даних взагалі не мають оцінки (0.0), що характерно для джерел на кшталт iNaturalist. Серед розмічених файлів переважають записи високої якості (оцінки 3.0–5.0). Наявність дробових оцінок (наприклад, 3.5) пояснюється автоматичним зниженням базового балу на 0.5 за присутність фонових птахів на записі. З датасету було вилучено записи з рейтингом від 0.5 до 2.5.

```
--- Recording Quality (Rating) Distribution ---
Rating 0.0: 12849 files (36.14%)
Rating 0.5: 22 files (0.06%)
Rating 1.0: 147 files (0.41%)
Rating 1.5: 120 files (0.34%)
Rating 2.0: 598 files (1.68%)
Rating 2.5: 518 files (1.46%)
Rating 3.0: 2738 files (7.70%)
Rating 3.5: 1509 files (4.24%)
Rating 4.0: 8018 files (22.55%)
Rating 4.5: 2185 files (6.15%)
Rating 5.0: 6845 files (19.26%)
```

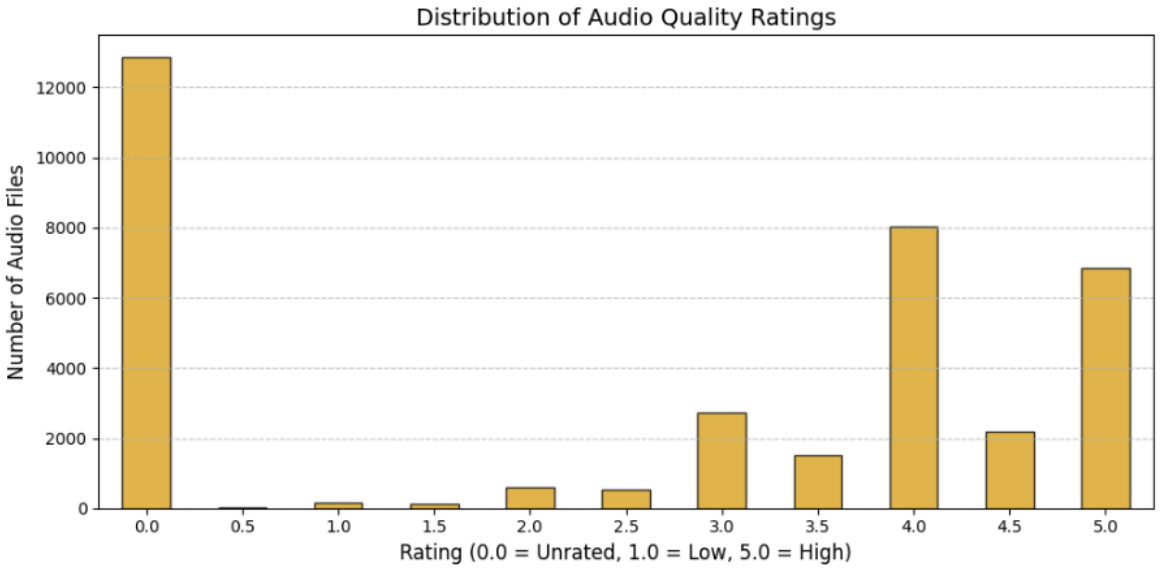


Рисунок 3 – Гістограма розподілу оцінок якості

Щодо фонових видів: аналіз показав, що майже 90% записів містять лише голос основного птаха ("соло"). Переважання "чистих" аудіо не відповідає реальним умовам лісу, де птахи співають одночасно.

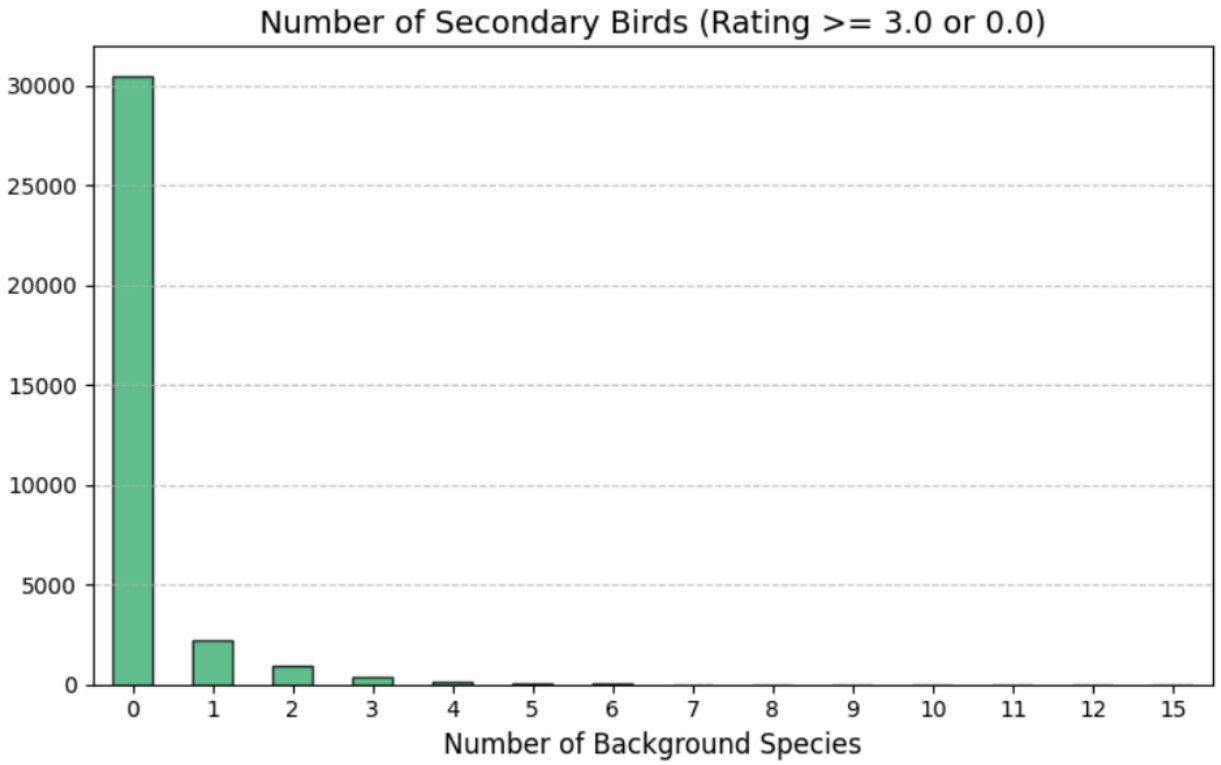


Рисунок 4 – Стовпчаста діаграма кількості фонових птахів

### 1.4. Проблеми співвідношення "Сигнал/Шум" та слабкої розмітки

Перетворення аудіо на Мел-спектрограми та їх візуальне (і слухове) дослідження на конкретних прикладах розкрило найголовнішу проблему датасету – так звану "слабку розмітку".

На багатьох довгих записах птах співає лише кілька секунд, а решта часу – тиша. Випадкове вирізання 5-секундного вікна з такого файлу неминуче згенерує для моделі навчальний приклад, де цільового сигналу фізично немає. Гучні артефакти (наприклад, пориви вітру) на спектрограмі можуть виглядати яскравіше за спів самого птаха. Модель може помилково навчитися асоціювати гучний вітер із певним видом. Широкосмуговий шум часто перекриває тихі вокалізації.

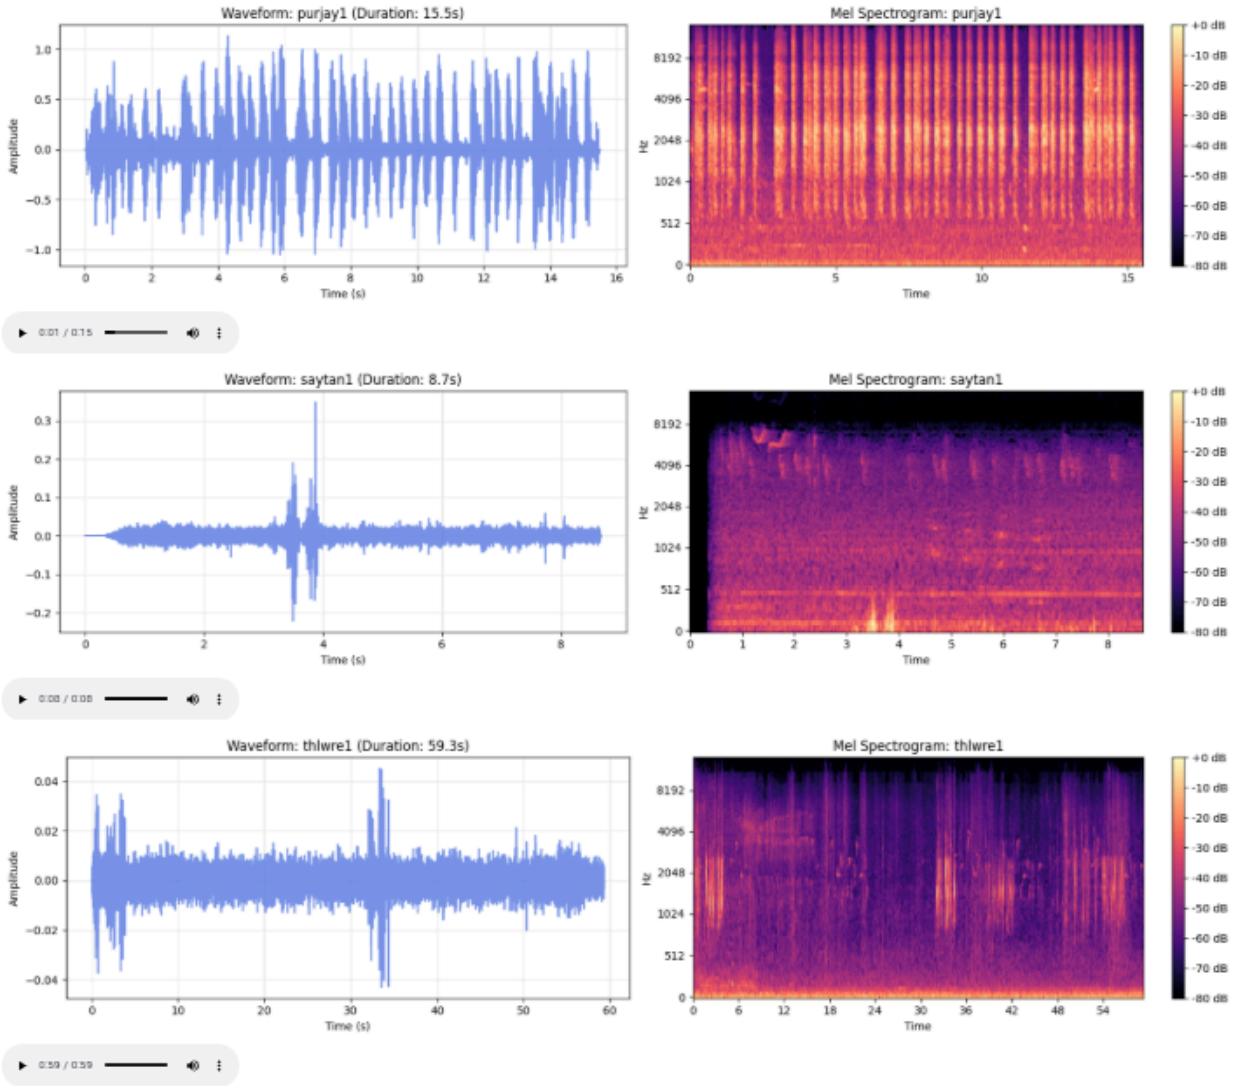


Рисунок 5 - Візуалізація осцилограм та Мел-спектрограм

### 1.5. Геопросторовий аналіз

Побудова інтерактивної карти місць запису аудіофайлів виявила яскраво виражене географічне упередження. Основний масив даних сконцентрований у Північній/Південній Америці та Європі. Африка, Азія та Австралія представлені мінімально. Модель може запам'ятати специфічний акустичний фон певного континенту, а не сам голос птаха.

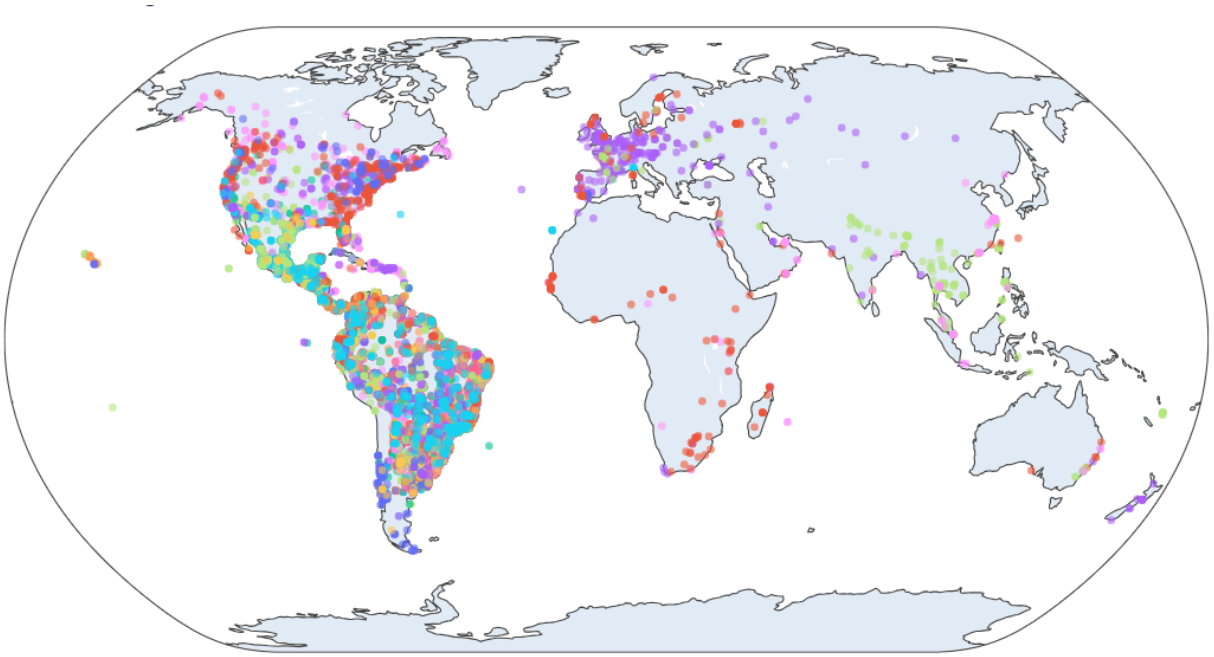

Рисунок 6 – Географічна карта розподілу тренувальних даних

### 1.6. Математичні основи та цифрова обробка Mel-спектрограм

У цьому розділі розглядається процес перетворення сирого аудіосигналу у візуальне представлення, придатне для аналізу згортковими нейронними мережами, з урахуванням особливостей біоакустики.

Ми подаємо батчі мел-спектрограм у будь-яку згортку.

Зауважимо, що Mel-спектрограма базується на особливостях людського (і загалом тваринного) слуху. Оскільки люди дуже добре розрізняють зміни в низьких частотах, але погано — у високих. Mel-шкала стискає високі частоти і розтягує низькі.

Фільтрація та стиснення даних (n_mels), оскільки звичайна спектрограма після перетворення Фур'є містить величезну кількість даних (наприклад, 2049 значень частот для n_fft=4096). У Mel-спектрограмі ми застосовуємо набір трикутних фільтрів (Filter Banks), які групують ці тисячі значень у невелику кількість «бінів» — n_mels.

- У розв'язку Бабича це було 224 біни, у Сидорського — 128 бінів. Це критично для нейромереж: ми викидаємо зайвий математичний шум і

залишаємо лише ті «смуги», де міститься корисна інформація про голос птаха.

- Звичайне перетворення Фур'є видає амплітуду. Проте ми сприймаємо гучність теж не лінійно. Тому Mel-спектрограму майже завжди переводять у логарифмічну шкалу (децибели) за допомогою операції AmplitudeToDB. Це дозволяє моделі однаково добре "чути" як дуже тихі звуки на фоні, так і дуже гучні крики поблизу мікрофона.

Зауважимо, що якби використовувалася звичайну спектрограму, вісь Freq у тензорі (Batch, Channels, Freq, Time) була б надто великою (наприклад, 2049). Більшість цих даних були б порожніми або містили б неважливий високочастотний шум.

Після перетворення Фур'є, де для кожного вікна маємо конкретну к-сть частот, які виділилося перетворення Фур'є, це зазвичай дуже багато (n_fft=2048 для кожного вікна - *друга половина — це просто дзеркальне відображення першої (від'ємні частоти)*).

- Точка №0 (0 Гц) — 1 штука.
- Точки від №1 до №1023 (корисні частоти) — 1023 штуки.
- Точка №1024 (частота Найквіста) — 1 штука. Завжди дорівнює половині частоти дискретизації, тобто якщо звукова карта записує звук із частотою 32 000 Гц (як у змаганні BirdCLEF), то частота Найквіста буде 16 000 Гц. Це означає, що все, що звучить вище за 16 кГц, ти вже не зможеш правильно оцифрувати.
- Точки від №1025 до №2047 (дзеркальні частоти) — 1023 штуки.

Оскільки треба зменшувати. Тож, використовуємо так званий **Mel Filter Ban**k (Набір Mel-фільтрів), яка відбувається тільки по осі частот (вертикально) для кожного конкретного моменту часу окремо.

- для трикутника у центрі вага завжди буде 1, по краям 0, а між краєм та центром вага змінюється пропорційно відстані.

- трикутники збільшуються за шириною, оскільки Mel-шкала логарифмічна, аби сприймали крок «однаково», на високих частотах потрібно охоплювати дедалі більший діапазон Герц. *Він ніколи не зменшується назад, бо наша здатність розрізняти частоти падає зі зростанням висоти звуку*
    - На низьких частотах (наприклад, 200 Гц) трикутник може мати ширину лише 50 Гц.
    - На високих частотах (наприклад, 12 000 Гц) той самий за «відчуттям» трикутник може мати ширину 2000 Гц.
- трикутники «сунуться» рівно на відстань між своїми вершинами, що створює 50% накладання площ сусідніх трикутників. Кожна частота Фур'є завжди обробляється двома фільтрами одночасно.
- якщо обирати M=224 трикутники, то на виході для кожного моменту часу (Time) отримається рівно 224 числа.
    - Будь-який трикутник математично задається лише 3 точками на осі частот — Лівий край (вага 0), Центр (вага 1.0), Правий край (вага 0). Ці 3 точки визначають нахил його «схилів».
    - Скільки саме чисел із 2049 потрапить у трикутник, залежить від його ширини.
        - У вузький низькочастотний трикутник може потрапити лише 2–4 частоти Фур'є. Саме тому на низьких частотах модель бачить дуже детальну картинку (кожна частота майже окремий бін).
        - У широкий високочастотний трикутник можуть потрапити сотні частот Фур'є (наприклад, 300–400 значень). Тож, на високих частотах модель бачить «середню температуру по палаті», бо один бін змішує сотні частот.

Щоб визначити інтервали (центри трикутників, куди їх ставити).

1. Необхідно спочатку визначити діапазон Герц у вікнах, наприклад, для BirdCLEF це від 0 до 16000 ГЦ. Переводимо ці межі в Мели за формулою

$m=2595*log_{10}(1+\frac{f}{700})$. Отже, підставивши межі, які в ГЦ (0 та 16000) у формулу - отримаємо 0 та 3570 Мел.

- числа 700 та 2595 це константи, де 700 кутова частота, бо все що нижчу 700 ГЦ ми сприймає лінійно, вище 700 вже сприймає логарифмічно (тобто майже не відчуємо різницю між 10 000 Гц та 10 010 Гц - «один і той самий високий писк»). 2595 це коефіцієнт масштабування, для зручності в розрахунку, щоб кругле число в Герціх відповідало круглому числу в Мелах, 1000 Гц давало 1000 Мел, а не якесь дуже маленьке число як 0.385.

2. Потім ділимо проміжок на відповідну к-сть інтервалів, тобто якщо треба аби було 224 біни, а нам потрібно 226 точок (щоб у кожного трикутника був лівий край, центр і правий край сусіднього). Треба поділити на 225, щоб накладалися 224 трикутників на 224 відрізки. $3570/225 \approx15.86$. Отже, 15.86 це крок у Меліх, тож центри трикутників у мелах будуть стояти в точках: 0, 15.86, 31.72, ..., 3570.

3. Оскільки будемо накладати трикутники на шкалу у Гц, що видала згорстка, то переведемо центри трикутників $m$ з Мелів у Герци за зворотньою формулою: $f=700(10^{\frac{m}{2595}-1})$. Отже, це буде: $0,m_1=10 Гц,...,m_100=2160 Гц, ..., 16000Гц$

4. Тепер треба перевести ці Герци в індекси масиву з 2049 чисел за формулою: $index=f*\frac{n_fft}{SR}$ тобто для BirdCLEF: $index=f*\frac{4096}{32000}$. Тож, $10 Гц -> 10*0.128\approx1.28 -> індекс 1; ...; 2160 Гц -> 2160*0.128\approx276.4 -> індекс 276$

*Це ідеально відповідає голосам птахів: їхні низькі звуки часто потребують точності, а високі свисти можна сприймати як загальну смугу енергії.*

Наприклад, щоб отримати 224 біни, нам потрібно не 224, а 226 опорних точок $(M+2)$, тобто ще додаткові 2 точки це лівий та правий краї, початок першого трикутника та кінець останнього відповідно. Та 224 вершини, що є центрами 224 трикутників. *Ми ділимо шкалу Mel на 225 рівних відрізків, а

потім переводимо ці точки назад у Герци.* Бо якби поділимо Герци на 225 рівних частин, отримали б звичайну лінійну спектрограму. Але хочемо імітувати вухо.

- На низьких частотах: коли ми переводимо рівні відрізки Мел-шкали назад, точки в Герцах виходять дуже густими (наприклад, кожні 20 Гц). Це дає моделі дуже детальну картинку низьких звуків.
- На високих частотах: ті самі рівні відрізки Мел-шкали після перетворення в Герци стають гігантськими інтервалами (наприклад, кожні 1000 Гц).
- Що, якщо в інтервалі немає жодної частоти? Навіть якщо трикутник дуже вузький, він все одно «зачепить» найближчі частоти Фур'є через накладання. Однак у сучасних бібліотеках використовується нормалізація: площу кожного трикутника роблять рівною 1. Це означає, що вузькі трикутники (де мало частот) мають «вищі» піки, а широкі (де сотні частот) — «нижчі». Це вирівнює енергію по всьому спектру.

Отже, птахи та комахи часто мають дуже високі голоси. Якби Бабич не збільшував ширину трикутників (використовуючи лінійну шкалу), високі звуки могли б «провалюватися» між вузькими фільтрами або створювати забагато шуму. Mel-шкала дозволяє моделі бачити високі частоти так само «чітко» (з точки зору важливості), як і низькі.

### 1.7. Архітектура SED-голови та механізми локалізації звукових подій

Після обробки бекбоном (наприклад, EfficientNet) тензор має вигляд (Batch,Channels,Freq,Time). Для ідентифікації коротких сигналів на фоні шуму використовується спеціалізована голова Sound Event Detection (SED).

- Batch, це к-сть різних Mel-спектрограм, які подавалися на вхід
- Channels це те саме, що канали в звичайній CNN (наприклад, 1280 каналів у EfficientNet-B0). Кожен канал "шукає" щось своє: один може реагувати

на різкий свист, інший — на низьке гудіння, третій — на ритмічне цвірінькання.

- Freq це вертикальна вісь Mel-спектрограми, але сильно стиснута бекбоном. *Якщо на вході було 128 Mel-бінів, то після страйдів мережі (наприклад, 1/32) залишиться лише 4. Це "стисла" інформація про те, в якому діапазоні (низькому, середньому чи високому) мережа знайшла ознаки.*
- Time це горизонтальна вісь (часова шкала), теж стиснута мережею. Наприклад, було 512 часових кроків, стало 16. Кожне з цих 16 чисел тепер репрезентує не 40 мс, а великий блок часу (наприклад, ~1.25 секунди). Це і є часова шкала. Якщо в 3-му блоці з 16-ти є висока активація, значить, птах співав десь на початку запису.

Тепер для цеглинка заходить у SED-голову (Sound Event Detection). Наприклад, для EfficientNet-B0 після всіх stride це може бути (B, 1280, 4, 16).

**1. Frequency Pooling.**

Для SED нам не потрібно знати, в якому саме з 4-х залишку бінів «сидить» птах. Бекбон вже витягнув усю частотну інформацію в канали (Channels). Тому ми позбуваємося осі Freq. Як це робиться?

- Зазвичай використовується AdaptiveAvgPool2d((1, None)), що є іструментом у PyTorch, що реалізовує ідею Global Average Pooling (GAP), або просто mean(dim=2). Тобто, якщо було (B, 1280, 4, 16), то для кожного з 16 часових кроків мережа бере 4 значення частотних бінів і обчислює їхнє середнє. Це відбувається незалежно для кожного каналу.
- *Тензор перетворюється з (B,C,F,T) на (B,C,T).* Оскільки після усереднення, наприклад, було $(B, 1280, 4, 16) -> (B, 1280, 1, 16)$. Після чого вимір зі значенням 1 зазвичай видаляється через squeeze, залишаючи (B, 1280, 16)).

- Тепер у кожному часовому кроці (T) у нас є вектор ознак довжиною C, який описує все, що відбувалося на всіх частотах одночасно.

**2. Тепер нам треба перетворити ці 1280 каналів у кількість класів птахів (наприклад, 264 види).**

а) Використати класифікаційний шар (Pointwise Convolution). Пропускаємо тензор крізь лінійний шар або згортку 1×1. Тож, тензор стає вигляду (B, Classes, T).

Це і є наші frame-level predictions (прогнози для кожного кадру). Якщо в 5-му часовому кроці значення для «Зяблика» високе — значить, він співав саме в цей проміжок часу.

Зауважимо, **для кожного класу існує свій унікальний набір ваг**. Коли ми створюємо шар nn.Conv1d або nn.Linear, ми вказуємо кількість вихідних каналів (наприклад, 264 класи птахів). Це означає, що всередині цього шару створюється 264 різні фільтри (або 264 вектори ваг).

- Фільтр для Зяблика: має 1280 ваг.
- Фільтр для Сови: має свої 1280 ваг.
- Фільтр для Орла: має ще інші 1280 ваг.

Коротко і просто: кожен такий фільтр — це «рецепт», який каже: «Візьми 20% ознак з каналу №5, відніми 10% з каналу №100 і додай 50% з каналу №1200 — і ти отримаєш ймовірність того, що це я».

Тобто фінально ваг буде 264*1280 = 337 920 параметрів

б) У розв'язках (як у Бабича) просто лінійного шару замало. *Чому? Бо в 5-секундному записі птах може співати лише 0.5 секунди, а все інше — це шум вітру. Якщо ми просто візьмемо середнє, то 4.5 секунди шуму «розмиють» той короткий спів, і модель видасть низьку ймовірність.* Використовується Attention-based Pooling, змушуючи модель саму обирати, на які моменти часу звертати увагу. Це працює так.

Тензор ознак (B,C,T) виходить після бекбону та Frequency Pooling, ми розгалужуємо його на дві окремі «голови» (зазвичай це дві згортки 1×1).

*Нам потрібно зробити дві речі: зрозуміти, що звучить, і вирішити, коли звук був найбільш чистим.*

1. Шлях Класифікації (Classification Head). Аналогічно застосовуємо згортку 1x1, аби перетворити, наприклад, 1280 абстрактних ознак у 264 конкретні класи птахів. Результатом буде тензор вигляду (B, 264, 16). Це Frame-level predictions — сирі прогнози (логіти) для кожного з 16 кадрів.

2. Attention Head (Шлях «Уваги»). Паралельно з класифікацією створюється ще одна згортка 1×1, яка видає ваги важливості для кожного кадру. Аналогічна згортка, де результатом буде тензор (B,264,16). Ми пропускаємо його крізь Softmax по осі часу, щоб сума ваг для кожного птаха дорівнювала 1.

Навіщо це? Бо в аудіо часто буває багато шуму (вітер, дощ). Attention буде казати моделі: «Ігноруй кадри 1–5, там тільки шум, але дивись на кадр 12 — там голос птаха найчіткіший».

3. Фінальне об’єднання (Weighted Sum)

Тепер ми множимо прогнози кожного кадру на їхню «вагу важливості» і додаємо їх: $Y_{clip}=\sum_{t=1}^{16} \operatorname{Softmax}(x_{attn})_t \cdot \operatorname{Sigmoid}(x_{cls})_t$

- Sigmoid: «Чи є тут птах?» (Незалежність). Він застосовується до кожного кадру окремо. Йому байдуже, що відбувається в сусідніх кадрах. його логіка проста: «Я дивлюся на кадр №5. Якщо я бачу там Зяблика, я ставлю 0.9. Якщо я бачу там ще й Сову, я і їй ставлю 0.8». Тож, у одному кадрі може бути багато птахів одночасно. Сума значень по кадру може бути хоч 10.0, хоч 100.0.
- Softmax «Який момент найважливіший?» (Конкуренція). Логіка така: «У мене є всього 1.0 (100%) "бюджету уваги" на весь 5-секундний запис. Якщо я віддам 0.9 кадру №12 (бо там найчистіший звук), то на всі інші 15 кадрів у мене залишиться лише 0.1». Тому сума всіх 16 значень по осі

часу для конкретного птаха завжди дорівнює 1.0. Оскільки хочемо відфільтрувати шум. Softmax «видавлює» шумні кадри до нуля, щоб підсвітити лише той один-єдиний момент, де сигнал найсильніший. Зауважимо, щоб видати результат для одного кадру, Softmax мусить побачити всі 16 кадрів одразу.

Що робити якщо класи є приховані?

1. Метод «Поріг впевненості» (Thresholding). Найпростіший, якщо жоден із 256 класів не набрав більше ніж 0.3 (або інший поріг), ми вважаємо, що це «Unknown» або просто шум. Однак, якщо нейромережа «надвпевненими» (overconfident). Модель може видати 0.8 на незнайомого птаха просто тому, що його тембр трохи схожий на Зяблика.

2. Ембеддинги та Метричне навчання (Metric Learning). Замість того, щоб дивитися тільки на фінальні 264 класи, ми дивимося на вихід бекбону — вектор ознак (Embedding) довжиною 1280. Отже, всі Зяблики в просторі ознак збираються в одну «хмару», Сови — в іншу. Коли приходить незнайомий птах, його вектор (ембеддинг) приземлиться десь далеко від усіх знайомих хмар. Якщо відстань від нового звуку до найближчого центру знайомого класу занадто велика — це 100% «прихований» клас або аномалія.

3. Клас «Фон» або «Інше» (Background Class). Додати спеціальний 257-й клас, куди під час тренування «скидають» усе: вітер, дощ, кроки людей, шум літаків. Однак наколи не збиреться датасет із «усіма іншими звуками світу». Прихований птах може бути занадто схожим на справжній спів, щоб потрапити в цей клас.

4. Температурне масштабування та Ентропія. Можна виміряти «рівень розгубленості» моделі (ентропію). Якщо модель впевнено каже «Зяблик — 0.9, інші — 0.01» — це знайомий клас. Якщо модель видає «Зяблик — 0.3, Сова — 0.25, Орел — 0.2» — це означає, що вона бачить щось схоже на багатьох одразу, але ні на кого конкретно. Це ознака того, що перед нами новий клас.

Найкращий захист від прихованих класів — це Contrastive Learning (наприклад, використання ArcFace або Triplet Loss). Так модель вчиться не просто «ставити галочку» навпроти назви птаха, а розуміти унікальний «відбиток голосу». Якщо відбиток не схожий на жоден із бази — ми його ігноруємо.*

Тож, треба змінити такі елемнети в архітектурі:

1. Зміна Loss-функції (Metric Learning). У звичайній моделі ми використовуємо CrossEntropyLoss. Вона просто каже: «Зроби так, щоб імовірність правильного класу була 1.0». Їй байдуже, наскільки далеко один від одного знаходяться «Зяблик» та «Сова» у просторі ознак. Отже, щоб **бачити нові класи, замінюємо CrossEntropyLoss на ArcFace, CosFace або Triplet Loss.** Отже, модель починає вчитися так, щоб усі записи одного виду птаха були в дуже щільній «хмарі» (кластері), а між різними видами була велика порожнеча (зазор/margin). Тепер є «мапа» звуків. Якщо новий звук потрапляє в порожнечу між відомими кластерами — це 100% новий клас.

2. Використання Ембеддингів замість Логітів. Беремо вихід бекбону перед класифікацією (наш вектор довжиною 1280). Під час тестування ми не просто дивимося на «Sigmoid», а рахуємо косинусну відстань між цим вектором та еталонними векторами птахів, які ми зберегли під час тренування. Якщо подібність до найближчого птаха менша за 0.4, ми сміливо кажемо: «Я не знаю, хто це, але це точно не хтось із моїх 256 знайомих».

3. Додавання «Шумового» класу (Trash Class). Ми додаємо в тренування величезну кількість звуків, які не є птахами (бензопили, літаки, людська мова, дощ), аби модель вчиться виділяти ознаки, які роблять птаха — птахом. Коли модель почує «прихованого» птаха, вона може не впізнати вид, але вона принаймні не переплутає його з вітром.

4. Можна змінити спосіб обчислення впевненості. Ми додаємо параметр Temperature (T) у Softmax: $\sigma(x)_i=\frac{e^{\frac{x_i}{T}}}{\sum_{j}{}e^{\frac{x_j}{T}}}$. Якщо ми

збільшуємо T, розподіл стає більш «пласким». Це допомагає під час тестування краще бачити, коли модель «сумнівається» (ентропія висока). Велика розгубленість моделі — це головний сигнал, що перед нами невідомий клас.

**3. Фінальні прогнози: Frame vs Clip**

На виході SED-голова зазвичай видає дві речі:

- Frame-level output: Ймовірності для кожного кадру (B,T,Classes). Це потрібно для локалізації звуку в часі.
- Clip-level output: Одна ймовірність на весь 5-секундний запис.
    - Де беруться кадри і «сплющуються» у часі. Але не просто через середнє значення (бо один гучний крик на фоні 4-х секунд тиші «розчиниться»), а через спеціальну формулу, наприклад Auto-Pooling або Log-Sum-Exp: $y_{clip} = log(\frac{1}{T}\sum_{t=1}{T} exp(y_t))$
        - $exp(y_t)$ підноситься кожне значення в експоненту. Це «підсилювач». Якщо значення велике (впевнений спів), воно стає гігантським. Якщо маленьке (тиша) — воно залишається крихітним.
        - $\sum_{t=1}{T} exp(y_t)$ додаються ці гігантські значення. Тепер один-два сильні піки домінують у всій сумі.
        - $\frac{1}{T}$ беремо середнє від цих експонент
        - $log(...)$ повертаємо результат назад у нормальний масштаб, щоб число не було нескінченно великим.

**1.9. Аналіз та реалізація переможного рішення (1-ше місце, BirdCLEF 2025)**

Микита Бабич побудував систему, що базується на тривалому контексті та ітеративному самонавчанні.

**1. Архітектурна база: SED + GeM Pooling**

Було використано архітектуру Sound Event Detection (SED), яка була описана вище, але з важливою модифікацією в механізмі агрегації.

- GeM (Generalized Mean) Frequency Pooling: замість звичайного середнього (AvgPool) він використав GeM pooling по осі частот. Це дозволяє моделі гнучкіше виділяти важливі частотні ознаки, де параметр p може бути навченим або фіксованим (у нього p=3). Тобто математика GeM Pooling: $GeM(x)=(\frac{1}{F}\sum_{f=1}^{F}x_{f}^{p})^{\frac{1}{p}}$, де
    - $x_f$ це значення в конкретному частотному біні.
    - $F$ кількість бінів (наприклад, у (B, C, F, T):(B, C, 4, 16) це 4).
    - $p$ ступінь (параметр «гнучкості»).
- Якщо $p=1$: Формула перетворюється на звичайне середнє значення (Average Pooling). Ми просто усереднюємо всі 4 біни.
- Якщо $p=\infty$: Формула починає працювати як Max Pooling. Вона ігнорує все і бере тільки один найсильніший бін.
- Якщо $p=3$: (як у Бабича): Це ідеальний компроміс. Модель приділяє більше уваги яскравим пікам (голосу птаха), але при цьому не ігнорує контекст навколо них так сильно, як це робить Max Pooling.

Птахи часто співають у дуже вузькому діапазоні частот. Якщо в одному біні є чистий свист, а в трьох інших — порожнеча, звичайне середнє значення просто «вб’є» цей свист, зробивши його в 4 рази тихішим. GeM дозволяє цьому свисту «вижити» і пройти далі в SED-голову.*

- Вхідні дані: він подавав 3 повторення однієї Мел-спектрограми як 3 канали (RGB), що дозволило використовувати стандартні бекбони, навчені на ImageNet.

- Мел-параметри: використовував 224 Мел-біни та великий n_fft=4096. Це було критично для розрізнення комах (Insecta) та амфібій, чиї звуки часто зосереджені у вузьких частотних діапазонах.

**2. Стратегія 20-секундних чанків**

Це було одним із головних відкриттів Бабича. Він з'ясував, що для птахів достатньо 5 секунд, але для комах та жаб (Amphibia/Insecta) потрібні довші записи, оскільки їхні виклики дуже повторювані та тривалі.

Однак  для нейромережі ця «картинка» (спектрограма) не стала в 4 рази більшою за розміром. Оскільки він збільшив крок вікна з 313 до 1252 без втрати швидкості, оскільки на виході ширина спектрограми (32000*20)/1252=511 проти того, що було (32000*5)/313=512

Для моделі EfficientNet-B0 в обох випадках на вхід приходить картинка шириною приблизно 512 пікселів. Тобто для відеокарти (GPU) навантаження однакове. Але в моделі Бабича в ці 512 пікселів «втиснуто» в 4 рази більше часу.

Тобто коли створюється спектрограма і застосовується перетворенння Фур'є береться шматок звуку. У Бабича це 4096 точок (n_fft=4096). І ось у стандартному 5-секундному підході ми стрибаємо на ~312 семплів вперед після кожного Фур'є. Однак Бабич у своїй моделі стрибає на 1252 семпли вперед (hop_length=1252 (збільшено в 4 рази!)).

**3. Multi-Iterative Noisy Student (Самонавчання)**

Це «серце» його рішення. Коли він вперше спробував просто додати немарковані дані, це не спрацювало. Магія почалася, коли він перейшов до підходу Noisy Student.

У змаганні BirdCLEF дані зазвичай діляться на два типи:

- Focal recordings (Розмічені): це короткі записи конкретного птаха, де ми точно знаємо: «тут співає Зяблик».
- Soundscapes (Нерозмічені або слабо розмічені): це довгі (часто багатогодинні) записи дикої природи. Організатори дають їх у великій кількості, але вони не кажуть, хто і в яку секунду там співає. Саме їх Микита використав як «сировину».

Також він використовував додаткові дані з Xeno-Canto — це зовнішня база, де тисячі записів птахів, які теж можна використовувати для навчання.

*MixUp з псевдо-лейблами*: він змішував чисті тренувальні дані з «шумними» немаркованими записами (soundscapes) у пропорції 0.5. Тобто він брав чистий запис птаха і на 50% накладає на нього шумний нерозмічений запис лісу. Учень має «почути» птаха крізь цей бруд.

Тобто він змінював амплітуду в аудіо! Оскільки він оброблював не 5 секунд, а 20 секунд (через жаб і комах), то маємо 2 аудіодоріжки по 20 секунд:

- Доріжка А: чистий запис птаха з датасету (focal data).
- Доріжка Б: шумний запис лісу (soundscape), для якого модель-вчитель уже зробила «пророцтво» (псевдо-лейбли).

Потім робиться змішування за формулою: $Результат=0.5×Доріжка А+0.5×Доріжка Б$

Тобто обидва звуки звучать одночасно протягом усіх 20 секунд, але кожен — у пів сили.

Варто зауважити, що бралася доріжка Б, яка вже було розмічена вчителем, крім того, зазвичай бралися ті немарковані записи, в яких модель-вчитель була найбільш впевнена (де сума ймовірностей псевдо-лейблів була високою). Тобто якщо уявити довгий запис лісу (soundscape), який триває, наприклад, 10 хвилин. Модель-вчитель «прослуховує» його і для кожного виду птаха (а їх 206+) видає ймовірності для кожного часового шматочка. Тому протягом усього запису для кожного кадру (який видав ймовірності, який там птах звучить) знаходився

максимум (найвище значення (пік)) по кожному птаху. Наприклад: Птах А — макс. ймовірність 0.9. Птах Б — макс. ймовірність 0.1. Птах В — макс. ймовірність 0.8. а потім додава ці максимуми між собою (0.9+0.1+0.8+...).

Чому висока сума — це круто? Це означає, що вчитель чітко «почув» або одного птаха дуже впевнено, або цілий хор різних птахів. Це «багатий» на інформацію запис. Низька сума  означала, що модель-вчитель сумнівається щодо всіх. Швидше за все, там або суцільний шум вітру, або птахи десь занадто далеко. Бабич вважав такі записи «брудними» і менш корисними для навчання.

Він вважав, що «чистіші» псевдо-лейбли краще вчать модель.

Аналогічно, якщо чистий запис був коротший за 20 секунд? То цей коротший запис ставився у випадкове місце всередині 20-секундного вікна, а все інше заповнював нулями (тишею).

*Power Transform для очищення*: щоб зменшити вплив помилкових прогнозів учителя, він застосовував степінь до отриманих ймовірностей псевдо-лейблів: $P_{new}=P_{old}^{p}$, де p>1. *Коли вчитель каже «ймовірність 0.7», це може бути помилкою. Якщо ми просто повіримо вчителю, учень вивчить його помилки.* Це працює як фільтр: низькі ймовірності стають майже нульовими, а високі (впевнені) — зберігаються. було застосовано степінь $P^{1.53}$, де $1.53 \sim \frac{1}{0.65}$\

- Якщо ймовірність була 0.9 (впевнено): $0.9^1.53 \approx 0.85$ (залишилася високою).
- Якщо ймовірність була 0.3 (невпевнено): $0.3^1.53 \approx 0.15$ (стала майже нульовою).

Таким чином, він «загострює» впевненість: слабкі сигнали відсікаються, а сильні залишаються. Це очищує псевдо-лейбли від «сумнівів» вчителя.

*Stochastic Depth*: у процесі самонавчання він додавав drop_path_rate = 0.15 (Dropout для цілих блоків мережі). Він випадковим чином «вимикає» цілі шари в нейромережі під час навчання. Це змушує модель шукати обхідні шляхи для розпізнавання звуку, роблячи її набагато стійкішою.

**4. Спеціалізована модель для жаб та комах**

Оскільки ці групи були дуже слабо представлені в основному датасеті, Микита створив окрему модель (EfficientNet-B0), навчену виключно на Amphibia та Insecta з використанням додаткових 700 видів із Xeno-Canto.

Це дало приріст у 0.002–0.003 на Leaderboard.

**5. Розумний інференс (Inference flow)**

*5.1 Sliding-window та Averaging Overlapping Predictions (саме фішкою інференсу (тестування))*

У процесі тренування нам не потрібно «прочісувати» кожну секунду файлу з накладанням. Навпаки, нам потрібна різноманітність, щоб модель не зазубрювала дані.

Замість того, щоб просто різати аудіо на шматки по 5 секунд, він зробив «ковзне вікно».

- Як це працювало: Він брав 20-секундний шматок звуку, отримував для нього прогнози, а потім «сунувся» вперед не на 20 секунд, а лише на 5 секунд.
- Ефект накладання: Таким чином, кожен конкретний 5-секундний відрізок аудіо потрапляв у поле зору моделі 4 рази (як частина різних 20-секундних контекстів).
- Averaging (Усереднення): Замість того, щоб брати один прогноз, він усереднював результати всіх чотирьох «поглядів» моделі на цей відрізок.

Тож, у батчі під час інференсу (тестування) модель отримує не просто нарізані шматки, а серію «кадрів» одного і того самого аудіо, які дуже сильно накладаються один на одного.

Це працює як Temporal TTA (Test-Time Augmentation). Якщо птах заспівав на самому краю вікна, модель могла його пропустити через брак контексту. Але

завдяки накладанню, цей самий спів в іншому вікні опиниться в центрі, і модель його чітко розпізнає. Це підняло його результат (LB score) на 0.002–0.003.

Тобто хоча під час тестування (інференсу) ваги моделі «заморожені» і не змінюються. Але результат (Score) на Leaderboard піднімається, оскільки коли звук птаха потрапляє на 1-шу або 20-ту секунду вікна, у моделі немає контексту «збоку». Через це вона може видати низьку ймовірність (наприклад, 0.3), хоча звук чіткий. Однак, завдяки зміщенню на 5 секунд, цей самий звук у наступному вікні опиниться в центрі (на 10-й секунді). Там модель бачить його ідеально і видає впевнені 0.9.

Leaderboard рахує твою точність на основі фінальних чисел у submission.csv

- Без TTA: якщо просто розрізала аудіо на шматки і птах потрапив на край, ти записала в файл «0.3». Система порівняла це з реальною міткою «1» і знизила тобі бал.
- З TTA (як у Бабича): отримуємо чотири прогнози для одного моменту: 0.3, 0.8, 0.9, 0.8.
- Середнє: (0.3+0.8+0.9+0.8)/4=0.7.
- Тож, 0.7 набагато ближче до істини («1»), ніж 0.3. Твоя помилка стала меншою, а отже, Score на Leaderboard виріс.

*5.2 Smoothing (Гауссівське згладжування)*

Це фінальний етап обробки перед тим, як записати числа у файл submission.csv.

У роботі було використано 7 моделей, після того, як вони видали фінальний прогноз, вмикається гауссівське ядро, щоб «причесати» отриману криву.

Після усереднення всіх вікон (TTA) він отримував криву ймовірності птаха у часі. Але нейромережі часто видають «рвані» прогнози (різкі стрибки вгору-вниз).

Тож, для виправлення цього він застосував згладжування з ядром [0.1, 0.2, 0.4, 0.2, 0.1].

Приклад, уявимо, що в ансамблі 7 моделей. Для одного конкретного виду (наприклад, Дятел) кожна модель видає свою криву ймовірності для 12 часових сегментів (кадрів):

- Модель 1: [0.9, 0.8, 0.0, 0.1, ...]
- Модель 2: [0.8, 0.7, 0.1, 0.0, ...]
- ... (і так всі 7 моделей).

НЕ згладжуємо кожну модель окремо. Спочатку змішуємо їх у одну «середню» криву для Дятла: $Середня ймовірність кадр №1 = \frac{M1+M2+...+M7}{7}$ Після цього залишається лише один рядок із 12 чисел для Дятла на все аудіо (це і є результат ансамблю). Наприклад: [0.85, 0.75, 0.05, 0.05, ...]. Ось тепер, коли є одна фінальна крива, застосовується ядро [0.1, 0.2, 0.4, 0.2, 0.1]. *Як обчислити новий «згладжений» Кадр №2?* Беруться значення сусідів і множать їх на ваги ядра. [Кадр 1: 0.85, Кадр 2: 0.75, Кадр 3: 0.05, Кадр 4: 0.05]:

- Сам Кадр 2 (центр): 0.75×0.4=0.30.
- Сусіди (Кадр 1 та Кадр 3): (0.85×0.2)+(0.05×0.2)=0.17+0.01=0.18.
- Дальні сусіди: оскільки зліва від Кадру 1 нікого немає, береться крайнє значення (nearest mode), тобто клонюємо крайня значення в нашому випадку Кадр 1: 0.85 (в протилежному випадку ймовірність останнього кадру), або 0, а справа — Кадр 4 (0.05×0.1=0.005).
- Фінальне значення для Кадру №2 ≈0.30+0.18+0.005=0.485.

Згладжування йде по всій часовій шкалі для кожного птаха окремо.

- Після ансамблю для птаха «Зяблик» ми маємо 12 значень (по одному на кожні 5 секунд запису).
- Функція згладжування проходить по цьому рядку з 12 чисел і перераховує кожне з них, враховуючи «сусідів» по часу.
- Це робиться незалежно для кожного з 206+ видів птахів.

Згладжувати один фінальний прогноз набагато швидше, ніж робити це 7 разів для кожної моделі окремо.

- Значення в поточному кадрі на 40% залежить від нього самого, на 20% — від сусідніх кадрів, і на 10% — від наступних за ними.
- Крива стає плавною, випадкові поодинокі «викиди» (помилки моделі) приглушуються, а стабільний спів підкреслюється.

*5.3 OpenVINO: Оптимізація швидкості*

Тут виникла технічна проблема: був ансамбль із 7 важких моделей. Kaggle дає ліміт часу (зазвичай 2 години на CPU), і звичайний PyTorch просто не встигав би все прорахувати.

Рішення було конвертація усі моделі (їхні бекбони) у формат OpenVINO.

OpenVINO — це бібліотека від Intel, яка максимально оптимізує математичні операції під процесори (CPU). Це дозволило йому робити інференс у кілька разів швидше і «втиснути» свій гігантський ансамбль у часові рамки змагання.

*5.4 Delta Shift TTA*

Це коли він робив прогноз не тільки для точного часу, а й трохи зміщував вікно (на дельта-значення). Це ще одна форма TTA, яка робить модель менш чутливою до того, в який саме мілісекундний момент почався спів птаха. Аналогічно пункту 5.1

### 1.9. Висновки до розділу 1

Проведений розвідувальний аналіз даних (EDA) підтвердив, що тренувальний датасет є складним і максимально наближеним до реальних "польових" умов. Головними викликами для майбутньої моделі стануть сильний дисбаланс класів, відсутність точної часової розмітки та значні перешкоди у вигляді нестабільного співвідношення сигнал/шум.

Аналіз теоретичних основ цифрової обробки сигналів та архітектурних особливостей сучасних систем ідентифікації звукових подій дозволяє зробити наступні висновки:

- Пріоритетність Mel-спектрограм: Використання Mel-шкали та логарифмічного перетворення амплітуди є фундаментальним етапом, що дозволяє адаптувати вхідні дані під особливості біоакустики. Стиснення частотної осі до 128–224 бінів за допомогою трикутних фільтрів забезпечує ефективну фільтрацію математичного шуму, зберігаючи при цьому критично важливі деталі пташиного співу на низьких частотах та узагальнюючи високочастотні сигнали.
- Ефективність SED-архітектури: Впровадження голови Sound Event Detection (SED) з механізмами Attention-based Pooling та GeM Pooling вирішує ключову проблему «розмиття» коротких сигналів у довгих записах. Використання ваг уваги дозволяє моделі автоматично ігнорувати шуми (вітер, дощ) та фокусуватися на найбільш інформативних кадрах (Frame-level), що критично для роботи з немаркованими soundscapes.
- Важливість часового контексту: Досвід переможця BirdCLEF 2025 Микити Бабича демонструє, що перехід від стандартних 5-секундних до 20-секундних вікон є стратегічним рішенням для розпізнавання складних груп, таких як Amphibia та Insecta. Збільшення кроку вікна (hop_length) дозволяє отримати ширший часовий контекст без додаткового навантаження на обчислювальні ресурси (GPU).
- Самонавчання як метод подолання доменного зсуву: Стратегія Multi-Iterative Noisy Student з використанням MixUp та Power Transform виявилася найбільш ефективним методом використання немаркованих даних. Це дозволяє моделі «учневі» перевершувати «вчителя», вивчаючи більш стійкі ознаки в умовах сильного зашумлення.
- Стабілізація результатів через пост-процесинг: Застосування методів Sliding Window TTA та Гауссівського згладжування є необхідною умовою для отримання високого балу на Leaderboard. Ці методи мінімізують

вплив крайових ефектів вікна та усувають випадкові аномальні сплески ймовірностей, роблячи фінальні прогнози біологічно релевантними та плавними.

- Технічна оптимізація: Перехід до формату OpenVINO підтверджує, що при роботі з великими ансамблями моделей (наприклад, із 7 важких бекбонів) програмна оптимізація під CPU є критичною для дотримання жорстких часових лімітів змагання.

Таким чином, сформована база методів і підходів створює надійний фундамент для побудови високоефективної моделі, здатної працювати в реальних умовах дикої природи з високою точністю та швидкістю обробки даних.

## 2. ОПИС ВИКОРИСТАНИХ ПІДХОДІВ

### 2.1. Підхід №1: Базовий CNN (EfficientNet-B0 Baseline)

Перший етап дослідження фокусувався на побудові стабільної та швидкої моделі, яка сприймає аудіосигнал як задачу комп'ютерного зору (класифікація спектрограм).

- Представлення даних: аудіосигнал перетворювався у Log-Mel Spectrogram з використанням 128 мел-бінів та 5-секундного вікна аналізу. Вибір 128 бінів дозволив зберегти баланс між деталізацією частот та швидкістю обчислень, а логарифмічне стиснення амплітуди забезпечило однакову чутливість до тихих і гучних сигналів.
- Архітектура (Backbone): Використано мережу EfficientNet-B0. Ця модель була обрана як оптимальний компроміс: вона має достатню глибину для виділення складних акустичних патернів (свист, щебет, ритм), але залишається легкою для швидкого інференсу на ресурсах Kaggle.
- Методи регуляризації та аугментації:
    - SpecAugment: випадкове маскування смуг частот та часових проміжків. Це змушує модель не зазубрювати конкретні частоти, а шукати загальні ознаки голосу птаха.
    - Gaussian Noise & Gain: накладання білого шуму та варіювання гучності на рівні сирого аудіосигналу імітує різні умови запису (дистанція до птаха, вітер).
- Функція втрат: Застосовано BCEWithLogitsLoss (Binary Cross Entropy). На відміну від стандартної Cross Entropy, BCE дозволяє моделі прогнозувати присутність кількох видів одночасно (Multi-label classification), що є критичним для реальних записів дикої природи.

### 2.2. Підхід №2: Мультимодальна модель (CNN + Geocoordinates)

Оскільки ймовірність зустріти певний вид птаха залежить від локації, у другому підході було інтегровано метадані запису.

- Архітектура (Late Fusion):
    a. Аудіо-гілка: CNN витягує вектор ознак розмірністю 1280 (feature vector).
    b. Гео-гілка: MLP-мережа кодує широту та довготу (latitude, longitude) у вектор розмірністю 64.
- Метод злиття: конкатенація аудіо- та гео-векторів перед фінальним класифікатором.
- Логіка роботи: вектор ознак з аудіо-гілки конкатенувався (з'єднувався) з географічним вектором перед фінальним класифікаційним шаром. Це дозволило моделі «зважувати» візуальні ознаки спектрограми через призму географічної ймовірності.
- Логіка інференсу: при обробці немаркованих тестових записів (soundscapes), де координати можуть бути відсутні, гео-вектор заповнюється нулями, що робить модель універсальною.

### 2.3. Підхід №3: Покращений бекбон та 2-стадійне навчання

Фінальний підхід був спрямований на максимальне виділення складних ознак та стабілізацію градієнтів.

- Архітектура: перехід на бекбон EfficientNet-B2. Збільшення кількості параметрів дозволило краще розрізняти види з дуже схожим тембром.
- Стратегія Fine-tuning (2 етапи):
    - Stage 1: бекбон заморожений, тренується лише класифікаційна голова з великим Learning Rate (LR) протягом 3 епох. Це дозволило стабілізувати випадкові ваги голови без руйнування ознак, отриманих при попередньому навчанні на ImageNet.
    - Stage 2: бекбон розморожується, вся мережа донавчається з LR, зменшеним у 10 разів (2 епох).

- Нормалізація: впроваджено Per-frequency Instance Norm для спектрограм, що допомагає моделі адаптуватися до різних рівнів фонового шуму в різних частотних діапазонах.

## 3. ТАБЛИЦІ МЕТРИК ЯК НА ВАЛІДАЦІЇ ТАК І НА LEADERBOARD

| № моделі | Best Val AUC | Best Val mAP | Top-3 Accuracy | LB Score (Public) |
|---|---|---|---|---|
| Model 1 | 0.6820 | 0.0245 | 15.30% | 0.561 |
| Model 2 | 0.9418 | 0.4156 | 69.94% | 0.761 |
| Model 3 | 0.7371 | 0.0514 | 22.44% | 0.620 |

## 4. ПОРІВНЯННЯ З ПОПЕРЕДНІМИ ЗМАГАННЯМИ

Раніше (наприклад, у 2021-2023 роках) часто використовували F1-score, але в останніх змаганнях (2024–2026) стандартом стала метрика mAP (Mean Average Precision). Це змушує модель не просто вгадувати вид птаха, а правильно ранжувати ймовірності, що є складнішим завданням, ніж проста класифікація.

Кількість видів птахів змінюється щороку. У порівнянні з попередніми роками, BirdCLEF 2026 фокусується на специфічному регіоні. Кількість класів (234) вимагає архітектур з високою роздільною здатністю, таких як EfficientNet-B2, оскільки багато видів мають схожі акустичні сигнатури.

Аналіз попередніх змагань (2024, 2025) показав, що чисті аудіо-моделі досягають плато точності. Переможці минулих років почали впроваджувати географічні дані. У даній роботі підхід №2 (Late Fusion) підтвердив цю тенденцію: додавання координат дозволило підвищити mAP з 0.05 до 0.41, що корелює з успішними стратегіями топ-учасників минулих років.

Якщо у 2023 році домінували архітектури ResNet, то в поточному дослідженні використано EfficientNet-B0 та B2. Це дозволяє досягти кращих результатів при меншій кількості параметрів, що важливо для обмежених ресурсів інференсу на Kaggle

## 5. ГІПОТЕЗИ Й ДУМКИ, ЩОДО ОТРИМАНИХ РЕЗУЛЬТАТІВ

Модель №2 досягла AUC 0.94 та mAP 0.41, що значно перевищує результати чисто аудіо-моделей.

Чому так? Бо птахи мають чіткі ареали проживання. Інтеграція широти та довготи через MLP дозволяє моделі працювати як «фільтр»: якщо за координатами вид не зустрічається, модель занижує ймовірність навіть при схожому звуці. Крім того, метод Late Fusion (злиття на пізньому етапі) є оптимальним, оскільки дозволяє CNN сконцентруватися на обробці спектрограм, а MLP — на числових координатах, об'єднуючи їхні знання лише перед фінальним рішенням.

Хоча в Моделі №3 ми використовували складнішу архітектуру (B2) та двоетапне навчання, її результат (mAP 0.05) нижчий. Варто зауважити, що звичайно для чистого аудіо EfficientNet-B2 зазвичай потребує 20–40 епох, щоб вийти на пристойний рівень. Тож, Модель №3 дійсно недотренована через обмеження часу та ресурсів (всього 2 епохи розмороженого навчання). Однак модель №2 отримує «підказку», яка відразу відсікає 90% неправильних відповідей. Тому її метрики такі високі вже на старті. Тож, додавання контекстних метаданих (локації) має критично більший вплив на точність, ніж збільшення тривалості навчання або ускладнення архітектури бекбону.

Попри нижчі абсолютні показники, перехід від базового підходу №1 (EfficientNet-B0) до вдосконаленої стратегії з Моделлю №3 продемонстрував внутрішню ефективність: AUC зріс на 5.5%, а mAP — подвоївся. Це підтверджує, що методика Fine-tuning із заморожуванням бекбону на початкових етапах є вірною для стабілізації ваг класифікатора.

Отже, найбільш вражаючий приріст показала Модель №2. Хоча її аудіо-складова була простішою за Модель №3, додавання географічного контексту дозволило досягти LB Score 0.761, що на 20% вище за результати чисто акустичних моделей. Це доводить, що метадані локації є критично важливим фактором для ідентифікації видів птахів. Тож, для задачі BirdCLEF

якісні метадані є важливішим фактором ідентифікації птахів, ніж складність нейромережевого бекбону.