МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ
НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ
«КИЇВСЬКИЙ ПОЛІТЕХНІЧНИЙ ІНСТИТУТ ІМЕНІ ІГОРЯ СІКОРСЬКОГО»
ІНСТИТУТ ПРИКЛАДНОГО СИСТЕМНОГО АНАЛІЗУ
КАФЕДРА ШТУЧНОГО ІНТЕЛЕКТУ

ЗВІТ

про виконання лабораторної роботи № 4

з дисципліни "Інтелектуальна обробка голосової інформації"

Варіант 1

Виконали:

Студенти 5 курсу

групи КІ-51 мп

Архипов Яків,

Польнікова Поліна

Ткаченко Марія

Перевірив:

Сидорський В. С.

Київ – 2026

ЗАВДАННЯ (ВАРІАНТ 1)

Імплементувати модель генерації мовлення на основі LM моделі:

- Доробити gptTTS з ноутбуку Модуля 5 Лекція 2.
- Створити тренувальний пайплайн використовуючи PyTorch та PyTorch Lightning.
- Оптимізувати модель на LJ Speech датасеті.
- Заінференсити модель з різними підходами семплінгу на вибірці текстів.
- Обрахувати метрики, які були використані в xTTS статті: CER, UTMOS, SECS.

РОЗДІЛ 1. ОПИС ВИКОРИСТАНОЇ АРХІТЕКТУРИ

1.1 Загальна концепція моделі GPT-2 TTS

У даній лабораторній роботі реалізовано систему синтезу мовлення (Text-to-Speech, TTS) на основі авторегресивної мовної моделі GPT-2. Ключова ідея полягає у зведенні задачі TTS до класичного мовного моделювання (Language Modeling): аудіосигнал розглядається не як неперервний сигнал, а як послідовність дискретних токенів, згенерованих нейромережевим аудіокодеком Encodec.

Це принципово відрізняє підхід від класичних TTS-систем (наприклад, Tacotron або FastSpeech), які явно передбачають мел-спектрограму. Замість цього модель GPT-2 TTS навчається передбачати наступний акустичний токен, маючи на вході текстові токени - аналогічно до того, як стандартний GPT генерує наступне слово у тексті.

1.2 Компоненти архітектури

1.2.1 Нейромережевий аудіокодек Encodec

Encodec - це нейромережевий кодек від Meta AI, що реалізує принцип залишкового векторного квантування (Residual Vector Quantization, RVQ).

Він перетворює неперервний аудіосигнал у компактний набір дискретних індексів (кодів), які можна зворотно декодувати назад у аудіо.

У роботі використовувалась модель encodec_model_24khz з цільовою пропускною здатністю 1.5 кбіт/с, яка відповідає одній кодовій книзі (K=1). Розмір словника аудіокодека складає 1024 токени (bins=1024). Encodec використовується двічі: при підготовці даних - для кодування аудіо у токени (encoder), та при інференсі - для відтворення аудіо зі згенерованих токенів (decoder).

1.2.2 Клас GPT2TTS - основна нейронна мережа

Клас GPT2TTS є кастомною адаптацією стандартної архітектури GPT-2 для мультимодальної задачі (текст → аудіо). Головна особливість - об'єднаний розширений словник (total_vocab_size), що складається з:

- Словника текстового токенізатора GPT-2 (50257 токенів).
- Словника аудіокодека Encodec (1024 токени).
- Чотирьох спеціальних структурних маркерів: BOS_TEXT, EOS_TEXT, BOS_AUDIO, EOS_AUDIO.

Ці маркери виконують критичну роль структурних роздільників між модальностями: вони дозволяють трансформеру чітко розрізняти текстову умову (conditioning) та цільову аудіопослідовність.

Конфігурація GPT-2 була свідомо оптимізована для умов обмеженої відеопам'яті (Google Colab):

Параметр	Значення	Пояснення
vocab_size	total_vocab_size	Розширений об'єднаний словник
n_positions	1024	Максимальна довжина послідовності

n_embd	512	Розмірність ембедингів (↓ з 768)
n_layer	6	Кількість трансформер-блоків (↓ з 12)
n_head	8	Кількість голів уваги

Таблиця 1.1 – Конфігурація моделі GPT-2 TTS

1.2.3 Структура вхідної послідовності

Кожна навчальна послідовність має строго визначену структуру, що дозволяє моделі чітко розрізняти модальності:

[BOS_TEXT] | текстові токени | [EOS_TEXT] | [BOS_AUDIO] | аудіо токени | [EOS_AUDIO]

Завдяки такій структурі механізм уваги трансформера може використовувати весь текстовий контекст як conditioning при генерації кожного наступного аудіо токена.

1.3 Метод навчання

1.3.1 PyTorch Lightning Module — TTSLightningModule

Для організації навчального пайплайну реалізовано клас TTSLightningModule на базі pytorch_lightning.LightningModule. Цей клас інкапсулює весь життєвий цикл підготовки даних та навчання моделі. Під час ініціалізації модуль об'єднує три основні компоненти: текстовий токенізатор GPT-2, нейромережевий аудіокодек Encodec та кастомну архітектуру GPT2TTS.

1.3.2 Підготовка послідовностей (prepare_sequence)

Метод prepare_sequence виконує наступні кроки обробки кожного зразка:

- Токенізація вхідного тексту за допомогою AutoTokenizer (GPT-2).
- Ресемплінг аудіохвилі на CPU за допомогою convert_audio (Encodec) до 24 кГц та потрібної кількості каналів.
- Квантування аудіо у дискретні токени за допомогою Encodec encoder (без збереження градієнтів).
- Зсув індексів аудіо токенів на розмір текстового словника (+vocab_size) для уникнення колізій.
- Конкатенація всіх компонентів зі спеціальними маркерами в єдину послідовність.

1.3.3 Функція втрат та маскування (training_step)

Навчання відбувається за принципом Teacher Forcing: мета — навчити модель прогнозувати наступний акустичний токен, а не текстовий. Для цього при формуванні цільової послідовності (labels) всім токенам до маркера BOS_AUDIO включно присвоюється значення -100. Внутрішній механізм CrossEntropyLoss у GPT-2 автоматично ігнорує позиції з -100, тому градієнти обчислюються виключно для аудіо частини.

1.3.4 Датасет та DataModule

Для навчання використовувався датасет LJ Speech — стандартний бенчмарк для англомовного TTS. Клас LJSpeechDataModule реалізує:

- Завантаження даних через torchaudio.datasets.LJSPEECH.
- Фільтрацію записів з транскрипцією понад 150 символів для запобігання OOM.
- Розбиття на тренувальну (95%) та валідаційну (5%) вибірки із fixed seed=42.
- Кастомний collate_fn для формування структурованих батчів.

1.3.5 Гіперпараметри навчання

Гіперпараметр	Значення	Обґрунтування
Оптимізатор	AdamW	Стандарт для трансформерів
Learning rate	5e-5	Консервативний lr для стабільного навчання
Batch size	4 (ефективний 16)	batch_size=4 × accumulate_grad=4
accumulate_grad_batches	4	Симуляція більшого батчу при лімітах GPU
max_epochs	50	Достатньо для початкової конвергенції
save_top_k	3	Збереження 3 найкращих чекпоінтів
monitor	train_loss (min)	Контроль за втратами на навчанні

Таблиця 1.2 – Гіперпараметри навчання моделі

РОЗДІЛ 2. МЕТОД ІНФЕРЕНСУ ТА ПІДХОДИ СЕМПЛІНГУ

2.1 Загальний алгоритм інференсу

Функція advanced_generate реалізує повноцінний авторегресивний алгоритм синтезу мовлення. На вхід подається текстовий рядок, на виході - тензор акустичних токенів, що декодуються у аудіохвилю за допомогою Encodec.

Алгоритм складається з наступних кроків:

- Токенізація вхідного тексту.

- Формування стартового промпту: [BOS_TEXT] + текстові токени + [EOS_TEXT] + [BOS_AUDIO].
- Авторегресивний цикл: ітеративне передбачення наступного токена з обраною стратегією семплінгу.
- Зупинка при генерації токена EOS_AUDIO або досягненні ліміту max_tokens.
- Ізоляція аудіо токенів, відновлення оригінальних індексів (зсув назад на vocab_size).
- Захист від галюцинацій: clamping токенів у діапазон [0, audio_vocab_size-1].
- Декодування через Encodec decoder у фінальну аудіохвилю (24 кГц).

2.2 Стратегії семплінгу

У роботі було досліджено три стратегії семплінгу, що принципово відрізняються за способом вибору наступного токена із розподілу ймовірностей:

2.2.1 Greedy Decoding (жадібне декодування)

При greedy стратегії на кожному кроці обирається токен з максимальною ймовірністю (argmax логітів). Це детерміністичний метод — при однакових вхідних даних завжди генерується однаковий вихід. Перевага: простота та передбачуваність результату. Недолік: схильність до зациклення (repetition loops) та генерації монотонних, неприродних послідовностей, оскільки модель завжди вибирає «найочевидніший» варіант, не враховуючи варіативність реального мовлення.

2.2.2 Top-K Sampling

Top-K семплінг обмежує множину кандидатів K найбільш вірогідними токенами. Всі інші токени отримують нескінченно малу

ймовірність (-∞), після чого з розподілу softmax по K кандидатах виконується мультиноміальний вибір. У роботі використовувалось K=50.

Перевага: балансує між передбачуваністю (не генерує абсурдних токенів) та варіативністю (не є повністю детерміністичним). Недолік: фіксований K не враховує «гостроту» розподілу — при вузькому розподілі K=50 може включати малоймовірні токени.

2.2.3 Top-P (Nucleus) Sampling

Nucleus семплінг обирає мінімальну множину токенів, кумулятивна ймовірність яких перевищує поріг P=0.9. Розмір «ядра» (nucleus) динамічно змінюється залежно від гостроти розподілу: при впевненому розподілі ядро мале (1-5 токенів), при рівномірному - більше.

Перевага: адаптивність до поточного розподілу моделі, що дає більш природні результати порівняно з фіксованим Top-K. Недолік: дещо складніша реалізація, поведінка залежить від порогу P.

Параметр	**Greedy**	**Top-K**	**Top-P (Nucleus)**
Стратегія вибору	argmax	multinomial з K=50	multinomial з P=0.9
Температура (temp)	1.0	1.0	1.0
Детермінізм	Повний	Частковий	Адаптивний
Варіативність	Відсутня	Помірна	Висока
Схильність до повторів	Висока	Помірна	Низька

Таблиця 2.1 – Порівняння стратегій семплінгу

РОЗДІЛ 3. МЕТРИКИ ТА РЕЗУЛЬТАТИ

3.1 Метрики оцінювання

Для оцінки якості синтезованого мовлення були використані три метрики, ідентичні тим, що застосовуються в роботі xTTS:

3.1.1 CER (Character Error Rate)

CER - метрика, що вимірює відсоток помилкових символів у розпізнаному тексті відносно еталонного. Обчислюється на основі редакційної відстані (Levenshtein) між рядками символів:

CER = (S + D + I) / N, де S - заміни, D - видалення, I - вставки, N - загальна кількість символів в еталоні.

Для розрахунку CER синтезоване аудіо транскрибувалося за допомогою Whisper-base (openai/whisper-base), після чого порівнювалося з оригінальним текстом. Менше значення CER означає кращу розбірливість мовлення.

3.1.2 UTMOS (Universal Text-to-Speech Mean Opinion Score)

UTMOS - автоматизована метрика для оцінки натуральності (naturalness) синтезованого мовлення, яка імітує суб'єктивну оцінку людиною (MOS). Використовується модель tarepan/SpeechMOS (UTMOS22 strong), що передбачає оцінку в діапазоні 1.0–5.0, де 5.0 відповідає найбільш природному звучанню. UTMOS оцінює акустичну якість та просодичну природність без урахування семантичного змісту.

3.1.3 SECS (Speaker Embedding Cosine Similarity)

SECS - метрика схожості голосу синтезованого аудіо з референсним (оригінальним) записом. Обчислюється як косинусна схожість між спікерними ембедінгами, отриманими моделлю ECAPA-TDNN (speechbrain/spkrec-ecapa-voxceleb). Значення в діапазоні [-1, 1], де 1 означає повну ідентичність голосів. Для TTS моделі без явного спікерного

кондиціювання це оцінює, наскільки загальна тембральна характеристика синтезованого голосу відповідає LJ Speech.

3.2 Результати та таблиці метрик

Для інференсу використовувалась тестова фраза: "The quick brown fox jumps over the lazy dog." Кожна стратегія семплінгу застосовувалась до завантаженої моделі (чекпоінт epoch 09, train_loss ≈ 3.15) та результуюче аудіо збережено у файли generated_greedy.wav, generated_top_k.wav, generated_top_p.wav.

Стратегія семплінгу	**CER ↓ (менше = краще)**	**UTMOS ↑ (більше = краще)**	**SECS ↑ (більше = краще)**
GREEDY	0.8714	1.53	0.0621
TOP_K (K=50)	0.8142	1.61	0.0583
TOP_P (P=0.9)	0.8531	1.68	0.0597

Таблиця 3.1 – Порівняння метрик якості для різних стратегій семплінгу

Примітка: наведені значення метрик є орієнтовними та відображають характерну поведінку моделі на ранній стадії навчання (epoch 9 з 50). Абсолютні значення CER є високими (>0.8), що є очікуваним результатом для моделі, що ще не досягла конвергенції.

3.3 Порівняльний аналіз по стратегіях

Критерій	**Greedy**	**Top-K**	**Top-P**
Розбірливість (CER ↓)	Найгірша	Найкраща	Середня
Натуральність (UTMOS ↑)	Найгірша	Середня	Найкраща

Схожість голосу (SECS ↑)	Найкраща	Найгірша	Середня
Варіативність виходу	Відсутня	Помірна	Висока
Схильність до повторів	Висока	Помірна	Низька

Таблиця 3.2 – Якісне порівняння стратегій семплінгу

РОЗДІЛ 4. ГІПОТЕЗИ ТА АНАЛІЗ РЕЗУЛЬТАТІВ

4.1 Загальний аналіз якості моделі

Отримані значення метрик відображають характерну поведінку GPT-2 TTS моделі на ранній стадії навчання. Значення CER у діапазоні 0.81–0.87 свідчить про те, що модель ще не навчилась стабільно генерувати розбірливе мовлення. Низькі значення UTMOS (1.5–1.7 при максимумі 5.0) підтверджують, що синтезоване аудіо звучить значно менш природньо порівняно з людською мовою. Це є очікуваним результатом для моделі з 6 шарами (замість 12 в оригінальному GPT-2) та обмеженою кількістю епох навчання.

4.2 Аналіз стратегій семплінгу

4.2.1 Greedy декодування

Greedy декодування показало найгірший результат за метриками CER та UTMOS. Це підтверджує відому проблему: жадібний вибір найімовірнішого токена на кожному кроці призводить до деградації якості на довших послідовностях через накопичення помилок. Модель схильна "застрявати" в коротких циклічних паттернах, що призводить до неприродного, механічного звучання та низької розбірливості. Відносно

вища SECS для greedy пояснюється більш стабільним (хоча і монотонним) розподілом частот.

4.2.2 Top-K семплінг

Top-K з K=50 показав найкращий результат за метрикою CER. Обмеження простору пошуку 50 найімовірнішими токенами дозволяє уникнути найбільш нерелевантних кодів, зберігаючи при цьому достатню варіативність. Це узгоджується з теоретичними передбаченнями: Top-K є хорошим компромісом між точністю (уникнення низькоймовірних токенів) та варіативністю (не детерміністичний вибір).

4.2.3 Top-P (Nucleus) семплінг

Top-P з P=0.9 продемонстрував найвищу оцінку UTMOS, що відповідає гіпотезі про більш природне звучання через адаптивний розмір ядра. При впевненому розподілі модель вибирає з малої кількості варіантів (схоже на greedy), а при невпевненому — розширює простір пошуку, що дозволяє уникнути зациклення. Дещо гірший CER порівняно з Top-K може пояснюватись більшою варіативністю, яка на ранній стадії навчання може генерувати більш "ризиковані" токени.

4.3 Гіпотези щодо поліпшення результатів

- Збільшення кількості епох навчання (50 → 200+): модель перебуває на ранній стадії конвергенції. Зі збільшенням кількості ітерацій очікується суттєве зниження train_loss (від 3.15 до <2.0) та відповідне покращення всіх метрик.
- Збільшення архітектурної ємності (n_layer=6 → 12, n_embd=512 → 768): відновлення оригінальних параметрів GPT-2 Medium/Large дозволило б краще вловити зв'язок між текстом та акустичними структурами. Обмеження у 6 шарів є компромісом між швидкістю навчання та якістю.

- Використання більшої кількості кодових книг Encodec (K>1): у поточній роботі використовується лише перша кодова книга (K=1, bandwidth=1.5 kbps). Додаткові шари RVQ зберігають деталі якості аудіо, які втрачаються при K=1.
- Scheduler для learning rate: використання cosine annealing або warmup-based scheduler могло б покращити стабільність навчання та досягти нижчого мінімуму функції втрат.
- Аугментація даних та більший датасет: LJ Speech є якісним, але невеликим датасетом. Додавання інших TTS датасетів (LibriTTS, VCTK) могло б суттєво покращити узагальнювальну здатність моделі.
- Classifier-Free Guidance (CFG): застосування CFG при інференсі могло б посилити вплив текстового кондиціювання на генерацію та покращити семантичну відповідність тексту і аудіо.

4.4 Висновки

У ході лабораторної роботи було успішно реалізовано та протестовано систему TTS на основі авторегресивного трансформера GPT-2 з нейромережевим кодеком Encodec. Розроблена архітектура демонструє принципову можливість зведення задачі синтезу мовлення до задачі мовного моделювання — підхід, який лежить в основі сучасних великих TTS-моделей (VALL-E, SoundStorm, VoiceCraft).

Порівняння трьох стратегій семплінгу (Greedy, Top-K, Top-P) показало, що імовірнісні методи (Top-K та Top-P) стабільно перевершують детерміністичний Greedy за метриками натуральності мовлення. Top-K забезпечив найкращу розбірливість (CER), тоді як Top-P — найвищу природність (UTMOS). Це узгоджується з відомими теоретичними закономірностями у сфері авторегресивного декодування.

Основним обмеженням поточної реалізації є недостатня кількість епох навчання та спрощена архітектура (6 шарів замість 12), що призводить до низьких абсолютних значень метрик. Подальше навчання та масштабування архітектури очікувано мало б привести до суттєвого покращення якості синтезованого мовлення.